

在冻结的 1.8B 扩散语言模型上的 耦合多智能体语言流：控制变量诊断报告

项目 **ELF-MAS** · 阶段 3 · 数据集 **synth_2fact_v1** · 骨干 Cola-DLM (1.8B, 冻结) · 随机种子 0 · 2026-06-03

本报告记录第 3 阶段 Cola+MAS 设置中关于**角色条件化智能体专精化**的当前实验证据。内容涵盖：合成诊断数据集及其来源、模型与智能体的连接方式、解码与评测流程、各控制变体、目前已获得的消融矩阵结果，以及一个曾使两个基线失效、现已修复并加入守卫的实现缺陷。

1 数据集构建：synth_2fact_v1

synth_2fact_v1 不是公开或下载得到的基准数据集，而是一个程序化生成的**合成诊断数据集**，其构造方式保证了每个智能体的正确消融行为是由构造已知的。

来源。

- 生成器：src/elf_mas/data/synth_2fact.py。
- 设计规范：notes/synthetic_task_v1.md。
- 使用 `numpy.random.default_rng(seed=42)` 确定性生成。
- 以 HuggingFace Dataset 形式保存于 data/synth_2fact_v1/{train,eval}。

封闭世界知识图谱。固定的小词表——100 个人物、50 座城市、20 个国家、40 种职业、20 种爱好——通过五条关系模板组合（例如 `lives_in`: “X lives in Y”；`city_in`: “Y is in X”；以及 `capital_of`、`works_as`、`hobby_of`）。

条目内容。每个条目包含一个问题 Q 、仅提供给智能体 A 的私有上下文 ctx_A 、仅提供给智能体 B 的私有上下文 ctx_B ，以及一个简短的标准答案。每个上下文携带一条与问题相关的事实（若适用）外加 2–3 条同模式的干扰项，使模型必须有条件地使用其私有上下文，而非简单复制。

桶	问题 Q	ctx_A 相关事实	ctx_B 相关事实	标准答案	该桶的依据
AB	“What country is the city where Alice lives in?”	“Alice lives in Berlin.”	“Berlin is in Germany.”	Germany	需将 <code>lives_in</code> (A) 与 <code>city_in</code> (B) 复合
A-only	“What does Alice do for work?”	“Alice works as a pilot.”	(仅干扰项)	pilot	答案事实只在 A 中
B-only	“What country is Cairo in?”	(仅干扰项)	“Cairo is in Egypt.”	Egypt	答案事实只在 B 中
neither	“What hobby does Charlie enjoy?”	(无相关事实)	(无相关事实)	unknown	不可回答；检验虚构抑制

表 1: 每个桶各一条具体样例。桶归属即“哪个智能体的私有上下文严格必需”的标准答案。

2 数据集分布与桶语义

每个条目恰属于四个桶之一，依据是回答 Q 所需的私有上下文：**AB**（两者皆需，即两跳复合）、**A-only**（需 A）、**B-only**（需 B）、**neither**（任一上下文均无法回答）。

	AB	A-only	B-only	neither
设计比例	40%	25%	25%	10%
评测子集（观测， $n=200$ ）	82 (41.0%)	48 (24.0%)	53 (26.5%)	17 (8.5%)

表 2: 设计的桶比例与第 7 节消融矩阵所用 200 条评测子集的实际分布对比。AB（两跳）桶为主桶（ $n=82$ ，约 41%）。完整划分为训练集 50k / 评测集 5k。

该数据集的价值。由于每条样例所需的上下文由构造已知，数据集提供了一个由构造确定的消融预期：

- 移除智能体 A 应损害 **AB** 与 **A-only**。
- 移除智能体 B 应损害 **AB** 与 **B-only**。
- 同时移除二者应使 **AB/A-only/B-only** 崩溃，而 **neither** 维持在“unknown”下限。

这使得消融的特异性可以被直接检验。该任务是一个**受控的合成诊断任务**，并非标准的公开多智能体基准；其目的是检验机制，而非声称下游性能。

3 模型与智能体连接

冻结骨干。Cola-DLM: DiT (1829.9M 参数) 与 VAE (501.9M 参数)，全程冻结。**MAS 注入。**多智能体结构以块内、LoRA 风格的逐智能体交叉注意力形式，注入到 DiT 的第 {8, 12, 16, 20} 层（内部维度 512，8 个注意力头）。**双智能体结构。**智能体 A 接收 ctx_A ，智能体 B 接收 ctx_B ；问题 Q 以前缀条件方式提供。私有上下文仅经由 MAS 头进入模型（不进入前缀）。**可训练残差通路。**每个智能体的交叉注意力产生一个速度残差，经门控后加入冻结骨干的隐状态；门控偏置初始化为 -2 （初始门控值约 0.12），残差输出投影零初始化（未训练时注入为恒等）。可训练参数总量约 25.3M（双头配置）。

阶段	作用
问题 Q	前缀条件（KV 缓存预热；骨干冻结）
$\text{ctx}_A \rightarrow$ 智能体 A	私有上下文，仅经 MAS 交叉注意力头 A 注入
$\text{ctx}_B \rightarrow$ 智能体 B	私有上下文，仅经 MAS 交叉注意力头 B 注入
MAS 残差注入	在 DiT 第 {8, 12, 16, 20} 层加入门控的逐智能体速度残差
冻结 Cola-DLM DiT	在隐答案块上产生速度 v
冻结 VAE 解码器	将预测的干净隐变量解码为答案 token（见第 4 节）

表 3: 数据流。仅逐智能体交叉注意力头与门控可训练；DiT 与 VAE 冻结。

4 解码 / 评测流程

生成。答案块通过对隐序列进行整流流（rectified-flow）去噪得到：DiT（含 MAS 残差）预测速度 v ，由欧拉步从噪声向干净隐变量积分。**经冻结 VAE 解码。**干净隐变量估计采用 x -预测捷径 $z_{\text{clean}} = z_t - tv$ ，再经冻结的 Cola VAE 解码为 token。**辅助损失。**训练时在速度 MSE 之外，对这些 VAE 解码出的 token 施加 token 交叉熵损失（ $\lambda_{\text{CE}}=0.3$ ），以直接施压于“解码正确”（而非仅“类型正确”）的隐变量。

主指标：逐 token-ID 精确匹配 (EM)。对标准答案做 token 化，并直接比较前 K 个预测 token-ID。**文本级 EM 不作为主指标：**存在解码拼接伪影，会把答案 token 与其后的填充区 token 连在一起（例如 "Belgium"

+ 尾部区 $\rightarrow$ "BelgiumTor"), 因此即便首个答案 token 正确, 文本级 EM 仍可能读为 0%。

推理设置。 $T_{\text{inf}}=16$ 个欧拉步; 前缀条件并配合 KV 缓存预热; 消融矩阵通过在采样时对门控/上下文做消融得到 (AB 两智能体均激活; A_only 仅保留 A; B_only 仅保留 B; Neither 同时移除二者)。

5 变体定义

编号	名称	类型	目的
B0	full	—	具有私有 ctx_A 、 ctx_B 的两个角色条件化智能体 (被测模型)。
B6	identical_ctx	数据侧	两个智能体接收相同上下文: 检验差异化的私有上下文是否重要。
B7	context_shuffled	数据侧	跨样本打乱上下文: 破坏上下文-问题的对应关系。
B4	single_model	架构侧	在 $\text{concat}(\text{ctx}_A, \text{ctx}_B)$ 上的单个参数对齐头: 将耦合与纯容量分离。
B2	frozen_agents	架构侧	双头架构但冻结智能体变换 (仅训练门控): 检验训练后的智能体变换是否必要。

表 4: 各变体。数据侧变体仅改变馈入模型的上下文; 架构侧变体改变 MAS 接线或参与训练的参数。

6 结果: 消融矩阵

变体	Full EM	移除 A (B_only)	移除 B (A_only)	移除二者 (Neither)	Δ_a	Δ_b	解读
B0 full	0.585	0.159	0.000	0.000	+0.427	+0.585	两智能体均具因果作用; B 比 A 更关键
B4 single_model	0.317	0.305	0.159	0.000	+0.012	+0.159	参数对齐单头; 约为 B0 一半; 几乎不用 A 的上下文
B6 identical_ctx	0.256	0.049	0.012	0.000	+0.207	+0.244	EM 下降过半; 消融不对称性被压缩
B7 context_shuffled	0.061	0.012	0.012	0.000	+0.049	+0.049	近乎崩溃; 消融量小且对称
B2 frozen_agents	0.000	0.000	0.000	0.000	+0.000	+0.000	无 MAS 下限; 训练后的智能体残差必要

表 5: AB (两跳) 桶, 逐 token EM (取值 $[0, 1]$), 单一随机种子 (种子 0); 按 Full EM 排序。 $\Delta_a = \text{EM}(\text{full}) - \text{EM}(\text{移除 A})$; $\Delta_b = \text{EM}(\text{full}) - \text{EM}(\text{移除 B})$ 。移除 A/B_only 仅保留智能体 B; 移除 B/A_only 仅保留智能体 A。五个变体均有效, 且来自互不相同的检查点 (见第 7 节)。B0 行复现了此前一次独立的 30k 运行 (0.585), 与所报精度一致。

数据侧对照。 单调排序 $B0\ 0.585 \gg B6\ 0.256 \gg B7\ 0.061$, 其中消融不对称性在 B0 最强 ($\Delta_b=+0.585 > \Delta_a=+0.427$), 在 B6 被压缩, 在 B7 坍缩为近乎对称、近乎为零; 这与第 3 节由构造确定的消融预期一致, 支持”性能由角色差异化、且正确配对的私有上下文驱动, 而非仅由双头架构本身驱动” (渐变式: B6 仍保留部

分信号)。

架构侧对照。在参数对齐下 (约 25.3M 对 25.5M)，B0 (0.585) 几乎是单头 B4 (0.317) 的两倍，支持增益来自耦合的角色条件化而非纯容量；B4 的消融高度偏侧 ($\Delta_a=+0.012$ 、 $\Delta_b=+0.159$) 表明单头偏向 B 的上下文、几乎不整合 A 的上下文——正是两跳桶上预期的失败模式。B2 (`frozen_agents`) 坍塌至 0.000 (训练损失最高, 3.82)，支持训练后的智能体残差 (而非仅门控) 是必要的。以上结论均基于单一种子 (见后续步骤)。

7 实现缺陷与有效性说明

静默回退缺陷。在 `--lora_mode` 下，变体 `frozen_agents` (B2) 与 `single_model` (B4) 此前构建的其实是同一个双头 `full` 模型：LoRA 分支从未根据 `--variant` 分流。因此先前 B0/B2/B4 的检查点逐字节相同 (md5 `4c64d210...`，最终损失同为 1.7658)，那批 B2/B4 结果无效。**先前的 B2/B4 结果已废弃，不得引用。**有效变体 (B0/B6/B7) 不受影响，因为它们的差异在数据侧实现。(另外，一次初始解析曾把评测 JSON 的两个轴转置，得出错误的 B0 移除 $A=0.358$ ；修正值为 0.159，即上文所用。)

已加入守卫。一个运行期断言 (`assert_lora_variant_realized`) 现会在所请求变体未真正改变模型时显式报错：`single_model` 必须构建单头封装且参数对齐 (为双头基准的 $0.85\text{--}1.15\times$)；`frozen_agents` 的可训练 MAS 参数必须 $< 10\%$ ；`full/identical_ctx/context_shuffled` 必须训练 100%。评测路径还会在 `--variant` 与检查点记录的变体不一致时给出警告。

8 当前结果与后续步骤

变体	状态	备注
B0 <code>full</code>	已完成，有效	主结果 0.585 EM
B4 <code>single_model</code>	已完成，有效	0.317；参数对齐的容量对照
B6 <code>identical_ctx</code>	已完成，有效	0.256；数据侧对照
B7 <code>context_shuffled</code>	已完成，有效	0.061；数据侧对照
B2 <code>frozen_agents</code>	已完成，有效	0.000；无 MAS 下限
种子 1-2	尚未运行	目前所有变体均为单一种子
B2/B4 (先前 <code>sweep</code>)	无效，已废弃	静默回退为 <code>full</code> (见第 7 节)

表 6: 运行状态。当前所有结果均为单一随机种子 (种子 0)。

结论。五个变体现已全部有效。在该受控合成诊断任务上，结果支持角色条件化专精化：(i) AB 桶的 EM 及其消融不对称性随角色相关输入结构被移除而单调下降 ($B0 \gg B6 \gg B7$)，与由构造确定的消融预期相符；(ii) 在参数对齐下，耦合模型几乎是单头模型的两倍 (B0 0.585 对 B4 0.317)，支持增益来自耦合而非容量；(iii) 冻结智能体变换使性能坍塌至无 MAS 下限 (B2 0.000)，支持训练后的智能体残差是必要的。所有结果均为单一种子，故效应幅度尚未由方差界定，但定性排序在四个独立对照中一致。

后续步骤。(i) 为全部五个变体补充种子 1-2 以获得误差棒 (当前有空闲 GPU，可并行执行)。(ii) 提交数据集生成器 (`src/elf_mas/data/synth_2fact.py`) 以保证可复现——它目前仅存在于计算服务器上，未纳入仓库版本控制。